

Evidências de Implementação do MVP

Pipeline de Dados para Análise de Sentimento e Crítica de Cinema
IMDb e Rotten Tomatoes

Fagundes Pereira da Silva

Especialização em Ciência de Dados e Analytics - PUC-Rio

Ambiente: Databricks Free Edition / Serverless

Arquitetura: Dados Brutos → Bronze → Prata → Ouro → Análises

Este documento reúne as capturas de tela anexadas durante a implementação do MVP. As evidências são apresentadas em sequência cronológica e organizadas por etapa, permitindo acompanhar a construção cuidadosa do pipeline, suas validações intermediárias, a persistência das camadas e a produção das análises finais.

Organização das evidências

O conjunto contém **69 capturas**. Nenhuma captura foi descartada; a sequência abaixo preserva a evolução da implementação.

Seção	Quantidade de evidências
1. Preparação do ambiente e Dados Brutos	5
2. Bronze, profiling e tratamento inicial do IMDb	19
3. Tratamento dos dados Rotten Tomatoes	7
4. Integração e harmonização na camada Prata	11
5. Profiling da Prata e construção da camada Ouro	12
6. Fato, validação da Ouro e análises de negócio	12
7. Organização final do pipeline e catálogo	2
8. Metadados do catálogo	1

1. Preparação do ambiente e Dados Brutos

Evidência do ambiente Databricks, configuração inicial, Landing Zone/Volume e preparação da camada Bronze.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.


1. Preparação do ambiente e Dados Brutos

The screenshot displays the Databricks web interface. On the left is a sidebar with navigation options: New, Home, Learn, Workspace, Recents, Catalog (selected), Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, and SQL Warehouses. The main area is titled 'Catalog Explorer > workspace >' and shows the 'default' schema. Below this, there are tabs for Overview, Details, Permissions, and Policies. The 'Overview' tab is active, showing a 'Description' section with the text 'Default schema (auto-created)'. Below the description is a search bar 'Filter tables' and a row of buttons: Tables 0, Volumes 0, Models 0, Functions 0, Secrets 0, Services 0, Skills 0, and Connections 0. A 'Sort' dropdown is also present. Below these is a table with columns: Name, Owner, Created at, Popularity, and Comment. The table is currently empty, and a message at the bottom states: 'You either don't have access to any tables or there are no tables in this schema. Either contact your administrator or [create a new sample table](#).' The sidebar also shows a 'Catalog' section with a search bar and a tree view of the catalog structure: My organization > workspace > db_imdb_mvp > Tables (1) > bronze_imdb_reviews, Volumes (1) > volume_dados_brutos, and default (selected). The 'default' schema is highlighted in blue.

Figura 1. Evidência do ambiente Databricks, configuração inicial, Landing Zone/Volume e preparação da camada Bronze.

Arquivo original: image(20260927-163145).png | registro em 27/09/2026 às 16:31:45

1. Preparação do ambiente e Dados Brutos



The screenshot displays the Databricks Free Edition interface. The left sidebar contains navigation links: New, Home, Learn, Workspace, Recents, Catalog (selected), Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, and SQL Warehouses. The main area is divided into two panes. The left pane, titled 'Catalog', shows a tree view of the catalog structure: My organization > workspace > system > mvp3_eng_dados > dados_brutos > Volumes (1) > volume_dados_brutos (selected). The right pane, titled 'Catalog Explorer', shows the details of the 'volume_dados_brutos' volume. It includes a search bar, a description 'Landing Zone dos arquivos originais do MVP-3', and a table of files and directories. The table has columns for Name, Size, and Last modified. Two files are listed: 'rotten_tomatoes_critic_reviews.csv' (215.58 MB, 5 minutes ago) and 'rotten_tomatoes_movies.csv' (16.32 MB, 5 minutes ago). Below the table, there is a section 'About this volume' showing the owner 'fagundespereira@gmail.com' and a 'Tags' section with an 'Add tags' button.

Catalog Explorer > mvp3_eng_dados > dados_brutos >

volume_dados_brutos

Overview Files Details Permissions Policies

Description

Landing Zone dos arquivos originais do MVP-3

[/Volumes/mvp3_eng_dados/dados_brutos/volume_dados_brutos / rotten_tomatoes](#) Refresh Create directory

Filter files and directories at this level

Name	Size	Last modified
rotten_tomatoes_critic_reviews.csv	215.58 MB	5 minutes ago
rotten_tomatoes_movies.csv	16.32 MB	5 minutes ago

About this volume

Owner fagundespereira@gmail.com

Tags

Add tags

Figura 2. Evidência do ambiente Databricks, configuração inicial, Landing Zone/Volume e preparação da camada Bronze.
Arquivo original: image(20260927-181707).png | registro em 27/09/2026 às 18:17:07

1. Preparação do ambiente e Dados Brutos

The screenshot displays the Databricks web interface. On the left, a sidebar contains navigation links: Home, Learn, Workspace, Recents, Catalog (selected), Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, Data Engineering, and Runs. The main area is divided into two panels. The left panel, titled 'Catalog', shows a tree view under 'My organization' with folders for 'workspace', 'system', 'mvp3_eng_dados', 'bronze', 'dados_brutos', and 'Volumes (1)'. The 'volume_dados_brutos' folder is selected. The right panel, titled 'Catalog Explorer', shows the path 'mvp3_eng_dados > dados_brutos > volume_dados_brutos'. It includes a search bar, a 'Share' button, and an 'Upload to this volume' button. Below this, there are tabs for 'Overview', 'Files', 'Details', 'Permissions', and 'Policies'. The 'Overview' tab is active, showing a 'Description' of 'Landing Zone dos arquivos originais do MVP-3' and a file list. The file list has columns for 'Name', 'Size', and 'Last modified'. It contains one entry: 'IMDB Dataset.csv' with a size of '63.14 MB' and 'Last modified' '6 minutes ago'. Below the file list, there is a section 'About this volume' with the owner 'fagundespereira@gmail.com' and a 'Tags' section with an 'Add tags' button.

Catalog Explorer > mvp3_eng_dados > dados_brutos >

volume_dados_brutos

Overview Files Details Permissions Policies

Description

Landing Zone dos arquivos originais do MVP-3

/Volumes/mvp3_eng_dados/dados_brutos/volume_dados_brutos / imdb

Refresh Create directory

Filter files and directories at this level

Name	Size	Last modified
IMDB Dataset.csv	63.14 MB	6 minutes ago

About this volume

Owner fagundespereira@gmail.com


Tags

Add tags

Figura 3. Evidência do ambiente Databricks, configuração inicial, Landing Zone/Volume e preparação da camada Bronze.

Arquivo original: image(20260927-181737).png | registro em 27/09/2026 às 18:17:37

1. Preparação do ambiente e Dados Brutos



```
> See performance (1) ✓ Checked for improvements

=====
IMDb
=====

[UC_COMMAND_NOT_SUPPORTED.WITH_RECOMMENDATION] The command(s): input_file_name are not supported in Unity Catalog. Please use _metadata.file_path instead. SQLSTATE: 0AKUC
File <command-7137567010973547>, line 5
  2 print("IMDb")
  3 print("=" * 60)
----> 5 df_imdb_bronze.printSchema()
  8 print("\n" + "=" * 60)
  9 print("ROTTEN TOMATOES - FILMES")

^
File <command-7137567010973545>, line 11
  1 def ler_csv(caminho):
  2     return (
  3         spark.read
  4         .option("header", True)
  5         (...)
  6         .csv(caminho)
  7     )
----> 11 df_imdb = ler_csv(
  12     CAMINHO_IMDB
  13 )
  15 df_rt_filmes = ler_csv(
  16     CAMINHO_RT_FILMES
  17 )
  19 df_rt_avaliacoes = ler_csv(
  20     CAMINHO_RT_AVALIACOES
  21 )
```

Figura 4. Evidência do ambiente Databricks, configuração inicial, Landing Zone/Volume e preparação da camada Bronze.

Arquivo original: image(20260927-183028).png | registro em 27/09/2026 às 18:30:28

1. Preparação do ambiente e Dados Brutos

The screenshot displays the Databricks interface. On the left, a sidebar contains navigation links: Home, Learn, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, Data Engineering, Runs, and Data Ingestion. The main area is titled 'Catalog Explorer' and shows the 'mvps_eng_dados' catalog. Under this catalog, the 'bronze' schema is selected, showing 3 tables: imdb_avaliacoes, rt_avaliacoes, and rt_filmes. The 'Overview' tab is active, displaying a description, a filter table search, and a table list. The table list shows 3 tables: imdb_avaliacoes, rt_avaliacoes, and rt_filmes, all owned by fagundespereira@gmail.com and created on Sep 27, 2026. The 'About this schema' section shows the owner as fagundespereira@gmail.com. The 'Tags' section has an 'Add tags' button. The 'Policies' section is partially visible at the bottom.

Figura 5. Evidência do ambiente Databricks, configuração inicial, Landing Zone/Volume e preparação da camada Bronze.


Arquivo original: image(20260927-184648).png | registro em 27/09/2026 às 18:46:48

2. Bronze, profiling e tratamento inicial do IMDb

Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot displays the Databricks interface with the notebook '03_profiling_qualidade_bronze' open. The notebook is running a PySpark query that orders data by 'percentual_nulos' in descending order. The output shows a table with 5 rows and 3 columns: 'coluna', 'quantidade_nulos', and 'percentual_nulos'. All values for 'quantidade_nulos' and 'percentual_nulos' are 0.

```
df_nulos_imdb.orderBy(F.desc("percentual_nulos"))
```

IMDb - Valores nulos

	coluna	quantidade_nulos	percentual_nulos
1	review	0	0
2	sentiment	0	0
3	_fonte	0	0
4	_arquivo_origem	0	0
5	_data_ingestao	0	0

5 rows | 2.353s runtime | Refreshed 11m ago

Figura 6. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190408).png | registro em 27/09/2026 às 19:04:08

2. Bronze, profiling e tratamento inicial do IMDb

The screenshot shows the Databricks workspace interface. The top navigation bar includes the Databricks logo, a search bar, and a 'Verify identity' button. The left sidebar contains a 'New' button and a list of workspace components: Home, Learn, Workspace (selected), Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, Data Engineering, Runs, and Data Ingestion.


The main workspace area displays a notebook with the following content:

- File Edit View Run Help Python Full Last edit was 5 minutes ago
- Run all Serverless Schedule
- > [See performance \(3\)](#) ✓ Checked for imp
- > `df_nulos_rt_filmes: pyspark.sql.connect.dataframe.DataFrame = [coluna: string, quantidade_nulos: long ... 1 more field]`
- Rotten Tomatoes - Filmes - Valores nulos
- Table +
- Table with 4 columns: `coluna`, `quantidade_nulos`, `percentual_nulos`, and an unnamed column.
- 25 rows 2.086s runtime
- Refresh

	<code>coluna</code>	<code>quantidade_nulos</code>	<code>percentual_nulos</code>	
1	<code>critics_consensus</code>	8578	48.43	
2	<code>authors</code>	1542	8.71	
3	<code>original_release_date</code>	1166	6.58	
4	<code>production_company</code>	499	2.82	
5	<code>audience_status</code>	448	2.53	
6	<code>streaming_release_date</code>	384	2.17	
7	<code>actors</code>	352	1.99	
8	<code>movie_info</code>	321	1.81	
9	<code>runtime</code>	314	1.77	
10	<code>audience_count</code>	297	1.68	
11	<code>audience_rating</code>	296	1.67	
12	<code>directors</code>	194	1.1	
13	<code>tomatometer_status</code>	44	0.25	
14	<code>tomatometer_rating</code>	44	0.25	
15	<code>tomatometer_count</code>	44	0.25	

Figura 7. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.
Arquivo original: image(20260927-190446).png | registro em 27/09/2026 às 19:04:46

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot shows the Databricks interface with a notebook titled "03_profiling_qualidade_bronze". The notebook is running a Python script that displays a table of null values for Rotten Tomatoes reviews. The table has columns: "coluna", "quantidade_nulos", and "percentual_nulos". The rows list various review attributes along with their respective null counts and percentages.


	coluna	quantidade_nulos	percentual_nulos
1	review_score	305936	27.07
2	review_content	65806	5.82
3	critic_name	18529	1.64
4	rotten_tomatoes_li...	0	0
5	top_critic	0	0
6	publisher_name	0	0
7	review_type	0	0
8	review_date	0	0
9	_fonte	0	0
10	_arquivo_origem	0	0
11	_data_ingestao	0	0

The table is titled "Rotten Tomatoes - Avaliações - Valores nulos". The notebook interface shows the execution time as 03:54 PM (3s) and the runtime as 3.019s. The table is refreshed 11m ago.

Figura 8. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190512).png | registro em 27/09/2026 às 19:05:12

2. Bronze, profiling e tratamento inicial do IMDb




The screenshot shows the Databricks workspace interface. The notebook is titled "03_profiling_qualidade_bronze" and is in the "Python" language. The output shows the number of duplicates for IMDb, RT Filmes, and RT Avaliações. The code snippet shows a display of a DataFrame grouped by sentiment and ordered by count in descending order. The table below shows the results of the query.

```
display(
  df_imdb
    .groupBy("sentiment")
    .count()
    .orderBy(
      F.desc("count")
    )
)
```

	sentiment	count
1	positive	25000
2	negative	25000

Figura 9. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.
Arquivo original: image(20260927-190538).png | registro em 27/09/2026 às 19:05:38

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot shows the Databricks workspace interface. The notebook '03_profiling_qualidade_bronze' is open, displaying a PySpark code snippet that groups reviews by type and counts them. The output is a table with two rows: 'Fresh' with a count of 720210 and 'Rotten' with a count of 409807.


```
display(
  df_rt_avaliacoes
    .groupBy("review_type")
    .count()
    .orderBy(
      F.desc("count")
    )
)
```

	review_type	count
1	Fresh	720210
2	Rotten	409807

Figura 10. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190554).png | registro em 27/09/2026 às 19:05:54

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot shows the Databricks interface with a notebook titled '03_profiling_qualidade_bronze'. The notebook is in 'Python' mode and shows a code cell that has been executed. The code is as follows:

```
display(
    df_rt_avaliacoes
    .groupBy("top_critic")
    .count()
    .orderBy(
        F.desc("count")
    )
)
```

Below the code cell, a table is displayed with the following data:

	top_critic	count
1	False	841481
2	True	288536

Figura 11. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.
Arquivo original: image(20260927-190615).png | registro em 27/09/2026 às 19:06:15

2. Bronze, profiling e tratamento inicial do IMDb




Figura 12. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190639).png | registro em 27/09/2026 às 19:06:39

2. Bronze, profiling e tratamento inicial do IMDb




Figura 13. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190654).png | registro em 27/09/2026 às 19:06:54

2. Bronze, profiling e tratamento inicial do IMDb





Figura 14. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190713).png | registro em 27/09/2026 às 19:07:13

2. Bronze, profiling e tratamento inicial do IMDb




The screenshot shows the Databricks workspace interface. The notebook '03_profiling_qualidade_bronze' is running, displaying a table of IMDb review scores and counts. The table has two columns: 'review_score' and 'count'. The scores range from 1 to 5, with some scores having a count of 0. The notebook is running on a Serverless cluster.

	review_score	count
1	1	305936
2	3/5	90273
3	4/5	83659
4	3/4	72366
5	2/5	60174
6	2/4	47546
7	2.5/4	44994
8	3.5/4	34371
9	3.5/5	30885
10	B	24358
11	5/5	24139
12	2.5/5	21260
13	1/5	20709
14	1.5/4	20475
15	B+	19822

Figura 15. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190744).png | registro em 27/09/2026 às 19:07:44

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot shows the Databricks workspace interface. The notebook is named "03_profiling_qualidade_bronze" and is running a Python script. The output shows a table with 15 rows of data, including a column "review_date".

	^A _C review_date
1	1800-01-01
2	1923-01-01
3	1927-08-12
4	1927-09-23
5	1928-04-21
6	1929-02-01
7	1931-01-26
8	1932-01-01
9	1933-01-01
10	1934-02-22
11	1935-01-01
12	1935-08-01
13	1936-01-01
14	1937-10-02
15	1938-08-23

Figura 16. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190812).png | registro em 27/09/2026 às 19:08:12

2. Bronze, profiling e tratamento inicial do IMDb





Figura 17. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-190830).png | registro em 27/09/2026 às 19:08:30

2. Bronze, profiling e tratamento inicial do IMDb




The screenshot shows a Databricks notebook interface. The notebook is titled "03_profiling_qualidade_bronze". The code in the notebook includes a call to `display(df_indicadores)`. Below the code, a table view shows the results of the profiling for three datasets: IMDb, RT Filmes, and RT Avaliações. The table has columns for dataset, registros, duplicados, and problemas_campo_principal.

	dataset	registros	duplicados	problemas_campo_principal
1	IMDb	50000	418	0
2	RT Filmes	17712	0	0
3	RT Avaliações	1130017	119471	0

Figura 18. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.
Arquivo original: image(20260927-190853).png | registro em 27/09/2026 às 19:08:53

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot displays the Databricks workspace interface. The notebook '03_profiling_qualidade_bronze' is open, showing a Python script that has been executed. The output of the script is visible, indicating a successful completion of the profiling process for the 'CAMADA BRONZE'. The output includes a summary of the datasets analyzed and the dimensions evaluated.

```
03:59 PM (<1s) 20 Python  
print("05_rt_filmes_prata")  
print("06_rt_avaliacoes_prata")  
  
===== PROFILING DA CAMADA BRONZE CONCLUÍDO =====  
  
Datasets analisados:  
✓ IMDb - Avaliações  
✓ Rotten Tomatoes - Filmes  
✓ Rotten Tomatoes - Avaliações  
  
Dimensões avaliadas:  
✓ Volume  
✓ Estrutura  
✓ Completude  
✓ Duplicidades  
✓ Domínios  
✓ Chaves  
✓ Integridade referencial  
✓ Campos textuais  
✓ Formatos de score e data  
  
Alterações nos dados:
```

Figura 19. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.
Arquivo original: image(20260927-190912).png | registro em 27/09/2026 às 19:09:12

2. Bronze, profiling e tratamento inicial do IMDb





Figura 20. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-193520).png | registro em 27/09/2026 às 19:35:20

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot displays the Databricks interface. The top navigation bar includes the Databricks logo and a search bar. The left sidebar shows the workspace structure with options like Home, Learn, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, and Marketplace. The main area shows a notebook titled '04_imdb_prata' with the following Python code:

```
df_imdb_prata = (
    df_imdb_prata
    .select(
        "id_avaliacao",
        "review",
        "sentiment",
        "sentimento",
        "fonte_dados",
        "data_hora_processamento"
    )
)

df_imdb_prata.printSchema()
```

The output of the code execution is shown below the code block:

```
> df_imdb_prata: pyspark.sql.connect.dataframe.DataFrame = [id_avaliacao: string, review: string ... 4 more fields]
root
 |-- id_avaliacao: string (nullable = true)
 |-- review: string (nullable = true)
 |-- sentiment: string (nullable = true)
 |-- sentimento: string (nullable = false)
 |-- fonte_dados: string (nullable = false)
 |-- data_hora_processamento: timestamp (nullable = false)
```

Figura 21. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-193540).png | registro em 27/09/2026 às 19:35:40

2. Bronze, profiling e tratamento inicial do IMDb




Figura 22. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-193556).png | registro em 27/09/2026 às 19:35:56

2. Bronze, profiling e tratamento inicial do IMDb

The screenshot displays the Databricks workspace interface. The notebook '04_imdb_prata' is active, showing a PySpark code cell with the following code:

```
.count()
.orderBy(
  "sentimento"
)
```

The execution result is a table with 2 rows:


	^A _C sentiment	^A _C sentimento	¹ ₃ count
1	negative	NEGATIVO	24698
2	positive	POSITIVO	24884

The interface also shows a sidebar with navigation options (Home, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace) and a top bar with search and user controls. The notebook execution status is 'Serverless' and 'Run all' is visible.

Figura 23. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-193612).png | registro em 27/09/2026 às 19:36:12

2. Bronze, profiling e tratamento inicial do IMDb



The screenshot shows the Databricks workspace interface. The notebook '04_imdb_prata' is open, displaying the following Python code and output:

```
print(
    f"Prata: "
    f"{qtd_prata:,"}
)

print(
    f"Removidos por duplicidade: "
    f"{qtd_bronze - qtd_prata:,"}
)
```

Output:

```
> df_imdb_prata_validacao: pyspark.sql.connect.dataframe.DataFrame = [id_avaliacao: string, review: string ... 4 more fields]
Bronze: 50,000
Prata: 49,582
Removidos por duplicidade: 418
```

Figura 24. Evidência de execução dos notebooks de Bronze, profiling de qualidade e preparação/tratamento dos dados IMDb.

Arquivo original: image(20260927-193630).png | registro em 27/09/2026 às 19:36:30

3. Tratamento dos dados Rotten Tomatoes

Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.

3. Tratamento dos dados Rotten Tomatoes




Figura 25. Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes.

Arquivo original: image(20260927-194830).png | registro em 27/09/2026 às 19:48:30

3. Tratamento dos dados Rotten Tomatoes




Figura 26. Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes.

Arquivo original: image(20260927-194844).png | registro em 27/09/2026 às 19:48:44

3. Tratamento dos dados Rotten Tomatoes




Figura 27. Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes.

Arquivo original: image(20260927-194907).png | registro em 27/09/2026 às 19:49:07

3. Tratamento dos dados Rotten Tomatoes

New

Home

Learn

Workspace

Recents

Catalog

Jobs & Pipelines

Compute

Discover

Marketplace

SQL

SQL Editor

Queries

Dashboards

Genie Agents

Alerts

Query History

SQL Warehouses

Data Engineering

Runs

Data Ingestion

Visual Data Prep

Catalog

Serverless Starter Wareho... Serverless 2XS

Catalog

Type to search

system

mvp3_eng_dados

bronze

Tables (3)

imdb_avaliacoes

rt_avaliacoes

rt_filmes

dados_brutos

Volumes (1)

volume_dados_brutos

default

No data

information_schema

ouro

No data

prata

Tables (2)

imdb_avaliacoes

rt_filmes

Shares received

samples

dbc-292e6d45-08fe.cloud.databricks.com/explore/data/mvp3_eng_dados/bronze?o=7474653114127242&activeListType=TABLE

Search data, notebooks, recents, and more...

Verify identity workspace

Catalog Explorer > mvp3_eng_dados >

bronze

Overview Details Permissions Policies

Description

AI generate Add

Filter tables

Tables 3 Volumes 0 Models 0 Functions 0 Secrets 0 Services 0 Skills 0

Connections 0

Sort

Name	Owner	Created at	Popularity	Comment
imdb_avaliacoes	fagundespereira...	Sep 27, 2026, 03...		
rt_avaliacoes	fagundespereira...	Sep 27, 2026, 03...		
rt_filmes	fagundespereira...	Sep 27, 2026, 03...		

About this schema

Owner fagundespereira@

Tags

Add tags

Policies

New policy

Figura 28. Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes. Arquivo original: image(20260927-195700).png | registro em 27/09/2026 às 19:57:00

3. Tratamento dos dados Rotten Tomatoes




Figura 29. Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes.

Arquivo original: image(20260927-201007).png | registro em 27/09/2026 às 20:10:07

3. Tratamento dos dados Rotten Tomatoes

The screenshot shows the Databricks workspace interface. The top navigation bar includes the Databricks logo, a search bar, and a 'Verify identity' button. The left sidebar contains a navigation menu with options like Home, Learn, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, Engineering, Runs, Data Ingestion, and Visual Data Prep. The main area displays a Python notebook titled '06_rt_avaliacoes_prata'. The notebook code consists of three print statements: '✓ integridade referencial avaliada', '✓ tabela Delta gravada', and '✓ persistência validada'. The output of the notebook shows a summary of the data processing: 'RT AVALIAÇÕES – CAMADA PRATA CONCLUÍDA', followed by statistics for Bronze and Prata layers, the number of removed duplicates, distinct IDs, and links without movies. A list of transformations performed is also shown, including handling duplicates, text fields, date conversion, and score normalization.

```
print(
    "✓ integridade referencial avaliada"
)

print(
    "✓ tabela Delta gravada"
)

print(
    "✓ persistência validada"
)
```

RT AVALIAÇÕES – CAMADA PRATA CONCLUÍDA

Bronze: 1,130,017
Prata: 1,010,546
Duplicados removidos: 119,471
IDs distintos: 1,010,546
Links de avaliações sem filme: 6

Transformações realizadas:

- ✓ duplicidades exatas tratadas
- ✓ campos textuais tratados
- ✓ data convertida
- ✓ top_critic convertido
- ✓ sentimento padronizado
- ✓ review_score original preservado
- ✓ identificador técnico único criado
- ✓ integridade referencial avaliada
- ✓ tabela Delta gravada
- ✓ persistência validada

Figura 30. Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes.

Arquivo original: image(20260927-202704).png | registro em 27/09/2026 às 20:27:04

3. Tratamento dos dados Rotten Tomatoes

```
print(  
    "IDs globais distintos: "  
    f"{ids_persistidos:,}"  
)  
  
print(  
    "\n✓ Persistência validada."  
)  
  
> See performance \(2\) Optimize  
  
> df_validacao: pyspark.sql.connect.dataframe.DataFrame = [id_avaliacao_global: string, id_avaliacao: string ... 14 more fields]  
Registros persistidos: 1,060,128  
IDs globais distintos: 1,060,128  
  
✓ Persistência validada.
```

Figura 31. Evidência das transformações e validações aplicadas aos dados de filmes e avaliações do Rotten Tomatoes.

Arquivo original: image(20260927-204530).png | registro em 27/09/2026 às 20:45:30

4. Integração e harmonização na camada Prata

Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.

4. Integração e harmonização na camada Prata

The screenshot displays the Databricks web interface. The main area shows a table named 'avaliacoes_harmonizadas' under the 'prata' catalog. The table has 15 columns with various data types and storage metrics. The left sidebar contains navigation links for different Databricks features. The right sidebar provides additional context and actions for the selected table.

Column	Type	Popul...	Comment	Tags	Column maskin...
id_avaliacao_global	string	...			
id_avaliacao	string	...			
fonte	string	...			
tipo_avaliador	string	...			
id_filme	string	...			
titulo_filme	string	...			
link_filme	string	...			
texto_avaliacao	string	...			
classificacao_original	string	...			
sentimento	string	...			
nota_original	string	...			
data_avaliacao	date	...			
nome_avaliador	string	...			
publicacao	string	...			
eh_top_critic	boolean	...			

Figura 32. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-210137).png | registro em 27/09/2026 às 21:01:37

4. Integração e harmonização na camada Prata



Figura 33. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-210208).png | registro em 27/09/2026 às 21:02:08

4. Integração e harmonização na camada Prata

```
32 f"{scores_convertidos:,}"
33 )

> See performance \(3\) ⊗ 1 ✓ Checked for improvements

[UNRESOLVED_COLUMN.WITH_SUGGESTION] A column, variable, or function parameter with name `nota_critico` cannot be resolved. Did you mean one of the following? ['top_critic', 'eh_top_critic', 'data_avaliacao', 'critic_name', 'fonte_dados']. SQLSTATE: 42703
== DataFrame ==
"col" was called from , line 20 in cell [29]


-----
AnalysisException                                Traceback (most recent call last)
File <command-7055442117566316>, line 22
      1 total_rt = df_rt_avaliacoes.count()
      3 scores_originais_preenchidos = (
      4     df_rt_avaliacoes
      5     .filter(
  (...)      14         .count()
      15 )
      17 scores_convertidos = (
      18     df_rt_avaliacoes
      19     .filter(
      20         F.col("nota_critico").isNotNull()
      21     )
--> 22     .count()
      23 )
      25 print(f'Registros RT: {total_rt:,}')
      26 print(
      27     f'Scores originais preenchidos: '
      28     f'{scores_originais_preenchidos:,}'
      29 )
```

Diagnose error Debug Genie Code Quick Fix: ON

Figura 34. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-211421).png | registro em 27/09/2026 às 21:14:21

4. Integração e harmonização na camada Prata



▶ 1 minute ago (<1s) 21

```
elif "nota_original" in colunas_rt:
    coluna_nota_original = "nota_original"
else:
    coluna_nota_original = None

if "nota_numerica" in colunas_rt:
    coluna_nota_convertida = "nota_numerica"
elif "nota_critico" in colunas_rt:
    coluna_nota_convertida = "nota_critico"
else:
    coluna_nota_convertida = None

print(
    "Campo da nota original: ",
    coluna_nota_original
)


print(
    "Campo da nota convertida: ",
    coluna_nota_convertida
)
```

Campo da nota original: review_score
Campo da nota convertida: None

Figura 35. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-212149).png | registro em 27/09/2026 às 21:21:49

4. Integração e harmonização na camada Prata



The screenshot displays a Databricks notebook interface. At the top, there are tabs for various notebooks: Home, _qualidade_bronze, 04_imdb_prata, 05_rt_filmes_prata, 06_rt_avaliacoes_prata, 07_integracao_harmonizacao_prata, and 08_profiling_qualidade_prata. The active notebook is 08_profiling_qualidade_prata. The interface includes a menu bar (File, Edit, View, Run, Help), a toolbar (Python, Full, Last edit was 7 minutes ago, Run all, Serverless, Schedule, Comments), and a code editor. The code editor shows a Python script that calculates the percentage of completed reviews. The script is as follows:

```
scores_preenchidos / total_rt * 100
if total_rt > 0
else 0
)

print(f"Registros RT: {total_rt:,}")
print(f"review_score preenchidos: {scores_preenchidos:,}")
print(f"review_score ausentes: {scores_ausentes:,}")
print(f"Percentual preenchido: {percentual_preenchido:.2f}%")
```

Below the code editor, the output of the script is displayed:

```
Registros RT: 1,010,546
review_score preenchidos: 736,941
review_score ausentes: 273,605
Percentual preenchido: 72.93%
```

The output is presented in a table format:

Registros RT:	1,010,546
review_score preenchidos:	736,941
review_score ausentes:	273,605
Percentual preenchido:	72.93%

Figura 36. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-213933).png | registro em 27/09/2026 às 21:39:33

4. Integração e harmonização na camada Prata

The screenshot shows a Databricks notebook interface. At the top, there's a status bar with a play button, a dropdown arrow, a green checkmark, the time '06:24 PM (1s)', the page number '24', the language 'Python', and icons for sharing, full screen, and a menu. The main area contains a PySpark code cell with the following code:

```
)  
  
display(  
    df_formatos_score  
    .groupBy("formato_score")  
    .count()  
    .orderBy(F.desc("count"))  
)
```

Below the code cell, there's a link 'See performance (1)' and a checkmark with the text 'Checked for improvements'. Below that, a variable declaration is shown: 'df_formatos_score: pyspark.sql.connect.dataframe.DataFrame = [id_avaliacao: string, rotten_tomatoes_link: string ... 13 more fields]'. At the bottom, there's a table view with the following data:

	^A _C formato_score	¹ ₃ count
1	FRACAO	620121
2	LETRA	115397
3	NUMERICO	1420
4	OUTRO	3

Figura 37. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-213955).png | registro em 27/09/2026 às 21:39:55

4. Integração e harmonização na camada Prata




Figura 38. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.
Arquivo original: image(20260927-214019).png | registro em 27/09/2026 às 21:40:19

4. Integração e harmonização na camada Prata




Figura 39. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-214041).png | registro em 27/09/2026 às 21:40:41

4. Integração e harmonização na camada Prata





Figura 40. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.
Arquivo original: image(20260927-214058).png | registro em 27/09/2026 às 21:40:58

4. Integração e harmonização na camada Prata




The screenshot shows the Databricks interface with a notebook titled "08_profiling_qualidade_prata". The notebook is written in Python and displays the output of a data profiling script. The output is a text-based report titled "PROFILING DE QUALIDADE - CAMADA PRATA".

```
=====
PROFILING DE QUALIDADE - CAMADA PRATA
=====
Registros harmonizados:          1,060,128
IDs globais distintos:          1,060,128
Duplicidades de ID global:      0
Sentimentos fora do domínio:    0
Links RT sem filme correspondente: 6
Avaliações RT associadas a esses links: 130
Reviews RT com score preenchido: 736,941
Reviews RT sem score:          273,605
Textos com menos de 10 caracteres: 850
=====
```

Figura 41. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-214116).png | registro em 27/09/2026 às 21:41:16

4. Integração e harmonização na camada Prata



The screenshot shows a Databricks notebook interface with a dark theme. At the top, there are tabs for various notebooks: Home, qualidade_bronze, 04_imdb_prata, 05_rt_filmes_prata, 06_rt_avaliacoes_prata, 07_integracao_harmonizacao_prata, and 08_profiling_qualidade_prata. The active notebook is 08_profiling_qualidade_prata. Below the tabs, there is a menu bar with File, Edit, View, Run, and Help. To the right of the menu bar are buttons for Python, Full, Last edit was 9 minutes ago, Run all, Serverless, Schedule, Comments, and Share. The main area of the notebook displays a Python code snippet that has been executed. The code is as follows:

```
f"△ foram identificadas "  
f"{scores_ausentes:,} avaliações RT "  
f"sem review_score"  
)  
  
print("\n✓ Validações críticas concluídas.")
```

Below the code, the output of the execution is displayed. It shows a list of validation results, each preceded by a checkmark (✓) or a warning triangle (△). The output is as follows:

```
✓ tabela harmonizada possui registros  
✓ identificador global é único  
✓ domínio de sentimento está consistente  
△ foram identificados 6 links RT sem filme correspondente  
△ foram identificadas 273,605 avaliações RT sem review_score  
  
✓ Validações críticas concluídas.
```

Figura 42. Evidência da integração das fontes, harmonização semântica e validações associadas à camada Prata.

Arquivo original: image(20260927-214140).png | registro em 27/09/2026 às 21:41:40

5. Profiling da Prata e construção da camada Ouro

Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.

5. Profiling da Prata e construção da camada Ouro




Figura 43. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-215933).png | registro em 27/09/2026 às 21:59:33

5. Profiling da Prata e construção da camada Ouro

The screenshot shows a Databricks workspace interface. At the top, there's a search bar and navigation tabs for various notebooks. The active notebook is '09_dimensoes_ouro'. The code in the notebook includes a print statement for 'Registros recebidos da Prata' and a display of a DataFrame. Below the code, the output shows the number of records (1,060,128) and a table with 7 columns: fontes_distintas, ids_filme_distintos, datas_distintas, fonte_nula, id_filme_nulo, and data_avaliacao_nula. The table has one row of data.

```
print(f"Registros recebidos da Prata: {total_prata:,}")

display(df_perfil_dimensoes)
```

> [See performance \(2\)](#) ✓ Checked for improvements

> df_perfil_dimensoes: pyspark.sql.connect.dataframe.DataFrame = [fontes_distintas: long, ids_filme_distintos: long ... 4 more fields]

Registros recebidos da Prata: 1,060,128

	1 ² ₃ fontes_distintas	1 ² ₃ ids_filme_distintos	1 ² ₃ datas_distintas	1 ² ₃ fonte_nula	1 ² ₃ id_filme_nulo	1 ² ₃ data_avaliacao_nula
1	2	17706	8015	0	49712	49582

Figura 44. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-215950).png | registro em 27/09/2026 às 21:59:50

5. Profiling da Prata e construção da camada Ouro




Figura 45. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-220024).png | registro em 27/09/2026 às 22:00:24

5. Profiling da Prata e construção da camada Ouro

The screenshot shows the Databricks workspace interface. The left sidebar contains navigation options: Home, Learn, Workspace (selected), Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, Data Engineering, Runs, and Data Ingestion. The top navigation bar includes a search bar, a 'Verify identity' button, and a 'workspace' dropdown. The main area displays a Python notebook with the following code and output:

```
display(df_dim_data.limit(20))
```

> [See performance \(1\)](#) [Optimize](#)

> df_dim_data: pyspark.sql.connect.dataframe.DataFrame = [id_data: integer, data_avaliacao: date ... 4 more fields]


Table view showing 20 rows of data:

	¹ ₃ id_data	¹ ₃ data_avaliacao	¹ ₃ ano	¹ ₃ trimestre	¹ ₃ mes	¹ ₃ dia
6	19290201	1929-02-01	1929	1	2	1
7	19310126	1931-01-26	1931	1	1	26
8	19320101	1932-01-01	1932	1	1	1
9	19330101	1933-01-01	1933	1	1	1
10	19340222	1934-02-22	1934	1	2	22
11	19350101	1935-01-01	1935	1	1	1
12	19350801	1935-08-01	1935	3	8	1
13	19360101	1936-01-01	1936	1	1	1
14	19371002	1937-10-02	1937	4	10	2
15	19380823	1938-08-23	1938	3	8	23
16	19390302	1939-03-02	1939	1	3	2
17	19391215	1939-12-15	1939	4	12	15
18	19391222	1939-12-22	1939	4	12	22
19	19410101	1941-01-01	1941	1	1	1
20	19410501	1941-05-01	1941	2	5	1

Figura 46. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-220047).png | registro em 27/09/2026 às 22:00:47

5. Profiling da Prata e construção da camada Ouro



The screenshot shows a Databricks workspace interface. The top navigation bar includes the Databricks logo, a search bar, and a 'Verify identity' button. The left sidebar contains a 'New' button and a list of workspace elements: Home, Learn, Workspace (selected), Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, and Engineering. The main area displays a Python notebook titled '09_dimensoes_ouro'. The notebook's toolbar shows 'File', 'Edit', 'View', 'Run', 'Help', 'Python', 'Full', and 'Last edit was 3 minutes ago'. The code in the notebook is as follows:

```
print("✓ novas chaves criadas somente quando necessárias")
print("✓ dimensões persistidas em Delta")
print("✓ unicidade das chaves validada")

print(
    "\nPróxima etapa: "
    "10_fato_avaliacao_ouro"
)
```

Below the code, the notebook output is displayed, showing the results of the execution:

```
=====
09_DIMENSOES_OURO – CONCLUÍDO
=====

Dimensões criadas:
✓ mvp3_eng_dados.ouro.dim_fonte
✓ mvp3_eng_dados.ouro.dim_filme
✓ mvp3_eng_dados.ouro.dim_data

Princípios preservados:
✓ camada Prata não modificada
✓ identificadores existentes reutilizados
✓ novas chaves criadas somente quando necessárias
✓ dimensões persistidas em Delta
✓ unicidade das chaves validada

Próxima etapa: 10_fato_avaliacao_ouro
```

Figura 47. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-220110).png | registro em 27/09/2026 às 22:01:10

5. Profiling da Prata e construção da camada Ouro





Figura 48. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-221314).png | registro em 27/09/2026 às 22:13:14

5. Profiling da Prata e construção da camada Ouro



```
Search data, notebooks, recents, and more... % + P Verify identity workspace
```

Home mes_prata. 06_rt_avaliacoes_prata 07_integracao_harmonizacao_prata 08_profiling_qualidade_prata 09_dimensoes_ouro 10_fato_avaliacao_ouro

File Edit View Run Help Python Full Last edit was 1 minute ago Run all Serverless Schedule Comments Share

07:05 PM (2s) 3 Python


```
assert total_prata == ids_avaliacao_distintos, (  
    "A granularidade da tabela harmonizada não é 1 avaliação por linha."  
)  
  
print("\n✓ Granularidade da entrada validada.")  
> See performance \(2\) Optimize
```

Registros da Prata: 1,060,128
IDs globais distintos: 1,060,128
Duplicidades encontradas: 0
✓ Granularidade da entrada validada.

Figura 49. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-221329).png | registro em 27/09/2026 às 22:13:29

5. Profiling da Prata e construção da camada Ouro



The screenshot displays the Databricks workspace interface. The top navigation bar includes the Databricks logo, a search bar, and a 'Verify identity' button. The left sidebar shows the workspace structure with options like Home, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL Editor, and Queries. The main area shows a notebook titled '10_fato_avaliacao_ouro' with a Python script. The script contains an assertion to check if the number of distinct IDs after joins matches the total number of records. The output of the script shows that the cardinality is preserved, with 1,060,128 records before and after the joins, and 0 difference in records.

```
assert ids_fato_distintos == total_prata, (  
    "A granularidade da fato foi alterada após os relacionamentos."  
)  
  
print("\n✓ Cardinalidade preservada.")  
> See performance \(2\) Optimize
```

07:07 PM (3s) 5

Registros antes dos JOINS: 1,060,128
Registros após os JOINS: 1,060,128
IDs globais distintos: 1,060,128
Diferença de registros: 0
✓ Cardinalidade preservada.

Figura 50. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-221346).png | registro em 27/09/2026 às 22:13:46

5. Profiling da Prata e construção da camada Ouro

The screenshot shows a Databricks workspace interface. At the top, there's a search bar and navigation tabs for various notebooks. The active notebook is '10_fato_avaliacao_ouro'. The code editor shows a Python snippet where a DataFrame is aliased as 'sem_id_data' and then displayed. Below the code, a table view of the DataFrame 'df_cobertura' is shown, containing one row of data.

```
07:08 PM (7s) 6 Python
```

```
    ).alias("sem_id_data")  
  
    display(df_cobertura)
```

> [See performance \(1\)](#) ✓ Checked for improvements


> df_cobertura: pyspark.sql.connect.dataframe.DataFrame = [sem_id_fonte: long, sem_id_filme: long ... 1 more field]

	¹ ₃ sem_id_fonte	¹ ₃ sem_id_filme	¹ ₃ sem_id_data
1	0	49712	49582

Figura 51. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-221402).png | registro em 27/09/2026 às 22:14:02

5. Profiling da Prata e construção da camada Ouro



The screenshot shows a Databricks workspace with a notebook titled '10_fato_avaliacao_ouro'. The notebook contains Python code for data validation and a summary of the results.

```
assert total_persistido == total_prata, (  
    "Quantidade persistida diferente da camada Prata."  
)  
  
assert ids_persistidos_distintos == total_persistido, (  
    "Existem IDs globais duplicados na tabela fato."  
)  
  
print("\n✓ Persistência e granularidade validadas.")  
> See performance \(2\) Optimize
```

The output of the notebook shows the following summary:

```
> df_fato_persistida: pyspark.sql.connect.dataframe.DataFrame = [id_avaliacao_global: string, id_avaliacao: string ... 12 more fields]  
Registros na Prata:          1,060,128  
Registros persistidos:      1,060,128  
IDs globais distintos:      1,060,128  
✓ Persistência e granularidade validadas.
```

Figura 52. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-221421).png | registro em 27/09/2026 às 22:14:21

5. Profiling da Prata e construção da camada Ouro

The screenshot shows a Databricks workspace interface. At the top, there's a search bar and navigation tabs for various notebooks. The active notebook is '10_fato_avaliacao_ouro'. The code in the notebook is a PySpark query that filters for non-null text evaluations and creates a summary DataFrame. The results are displayed as a table with 10 columns: registros, avaliacoes_distintas, fontes, filmes, datas, sem_fonte, sem_filme, sem_data, and s. The first row of data shows 1060128 records and 1060128 distinct evaluations.

```
df_resumo_fato = df_resumo_fato.filter(F.col("texto_avaliacao").isNotNull(), 1).otherwise(0)
df_resumo_fato.alias("sem_texto")

display(df_resumo_fato)
```


Table

	registros	avaliacoes_distintas	fontes	filmes	datas	sem_fonte	sem_filme	sem_data	s
1	1060128	1060128	2	17706	8015	0	49712	49582	

Figura 53. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.

Arquivo original: image(20260927-221439).png | registro em 27/09/2026 às 22:14:39

5. Profiling da Prata e construção da camada Ouro



The screenshot displays the Databricks interface with a notebook titled "10_fato_avaliacao_ouro". The notebook is in Python mode and shows the execution of a code cell. The output of the cell is as follows:

```
print(
    "\nPróxima etapa: "
    "11_validacao_qualidade_ouro"
)
```

10_FATO_AVALIACAO_OURO - CONCLUÍDO

Tabela criada:
✓ mvp3_eng_dados.ouro.fato_avaliacao

Registros:
✓ Prata: 1,060,128
✓ Ouro: 1,060,128

Validações:
✓ granularidade preservada
✓ id_avaliacao_global único
✓ relacionamento com dim_fonte validado
✓ registros sem filme preservados
✓ registros sem data preservados
✓ tabela persistida em Delta

Próxima etapa: 11_validacao_qualidade_ouro

Figura 54. Evidência de profiling da Prata, construção das dimensões e preparação do modelo analítico.


Arquivo original: image(20260927-221455).png | registro em 27/09/2026 às 22:14:55

6. Fato, validação da Ouro e análises de negócio

Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.

6. Fato, validação da Ouro e análises de negócio



```
▶ 4 minutes ago (<1s) 9 Python
```

```
print("✓ fato_avaliacao")

print(
    "\nPróxima etapa: "
    "12_analises_negocio"
)
```

```
=====
11_VALIDACAO_QUALIDADE_OURO - CONCLUÍDO
=====

Validações concluídas:
✓ contratos estruturais
✓ unicidade das chaves
✓ granularidade da tabela fato
✓ preservação Prata → Ouro
✓ integridade referencial
✓ completude das chaves obrigatórias
✓ consistência do domínio de sentimento
✓ cobertura dimensional documentada


Camada Ouro validada:
✓ dim_fonte
✓ dim_filme
✓ dim_data
✓ fato_avaliacao

Próxima etapa: 12 analises negocio
```

Figura 55. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-222733).png | registro em 27/09/2026 às 22:27:33

6. Fato, validação da Ouro e análises de negócio



```
File Edit View Run Help Python Full Last edit was 5 minutes ago Run all Serverless Schedule Comment
```

```
▶ 07:22 PM (<1s) 8 Python
```

```
print("=" * 68)
```

```
=====
```

```
VALIDAÇÃO DE QUALIDADE – CAMADA OURO
```

```
=====
```

```
VOLUMETRIA
```

```
Registros Prata:          1,060,128
```

```
Registros fato Ouro:      1,060,128
```

```
UNICIDADE
```

```
IDs de avaliação distintos: 1,060,128
```

```
INTEGRIDADE REFERENCIAL
```

```
Referências órfãs de fonte: 0
```

```
Referências órfãs de filme: 0
```

```
Referências órfãs de data: 0
```

```
COMPLETUDE / CONSISTÊNCIA
```

```
Sem id_avaliacao_global: 0
```

```
Sem id_fonte: 0
```


```
Sem id_filme: 49,712
```

```
Sem id_data: 49,582
```

Figura 56. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-222747).png | registro em 27/09/2026 às 22:27:47

6. Fato, validação da Ouro e análises de negócio



The screenshot shows a Databricks notebook interface with the following elements:


- Top Bar:** Navigation tabs for '08_profiling_qualidade_prata', '09_dimensoes_ouro', '10_fato_avaliacao_ouro', and '11_validacao_qualidade_ouro' (which is active). A 'New Notebook' button is on the right.
- Menu Bar:** 'File', 'Edit', 'View', 'Run', 'Help', 'Python', 'Full', and a timestamp 'Last edit was 5 minutes ago'.
- Code Editor:** Contains Python code for data validation:

```
07:21 PM (1s) 7
f"✓ avaliações com data associada: "
f"{percentual_com_data:.2f}%"
)
> See performance \(1\) ✓ Checked for improvements
```
- Output:** Displays two sections of results:
 - Validações críticas:**
 - ✓ id_avaliacao_global completo
 - ✓ id_fonte completo
 - ✓ sentimento consistente
 - Cobertura dimensional:**
 - ✓ avaliações com filme associado: 95.31%
 - ✓ avaliações com data associada: 95.32%
- Bottom Bar:** '+ Code', '+ Text', and 'Genie Code' buttons.

Figura 57. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-222802).png | registro em 27/09/2026 às 22:28:02

6. Fato, validação da Ouro e análises de negócio



The screenshot shows a Databricks notebook interface with the following elements:

- Top Bar:** Navigation tabs for '08_profiling_qualidade_prata', '09_dimensoes_ouro', '10_fato_avaliacao_ouro', and '11_validacao_qualidade_ouro' (selected). A 'New Notebook' button is on the right.
- Menu Bar:** File, Edit, View, Run, Help. Language mode is set to 'Python' and 'Full'. A status message says 'Last edit was 5 minutes ago'. Action buttons include 'Run all', 'Serverless', 'Schedule', and 'Comments'.
- Code Editor:** Contains Python code for validating orphan references. The code prints three lines of information and then asserts that the counts are zero.
- Output:** The execution results are displayed below the code, showing the printed messages and the final validation success message.

```
print(f"Referências órfãs - fonte: {orfãos_fonte:,}")
print(f"Referências órfãs - filme: {orfãos_filme:,}")
print(f"Referências órfãs - data: {orfãos_data:,}")

assert orfãos_fonte == 0
assert orfãos_filme == 0
assert orfãos_data == 0

print("\n✓ Integridade referencial validada.")
```

> [See performance \(3\)](#) ✓ Checked for improvements

Referências órfãs - fonte: 0
Referências órfãs - filme: 0
Referências órfãs - data: 0

✓ Integridade referencial validada.

Figura 58. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-222820).png | registro em 27/09/2026 às 22:28:20

6. Fato, validação da Ouro e análises de negócio

The screenshot shows a Databricks workspace interface. At the top, there's a search bar and a navigation bar with tabs for various notebooks: 'harmonizacao_prata', '08_profiling_qualidade_prata', '09_dimensoes_ouro', '10_fato_avaliacao_ouro', '11_validacao_qualidade_ouro', and '12_analises_negocio'. The '12_analises_negocio' tab is active. Below the tabs, there's a menu bar with 'File', 'Edit', 'View', 'Run', 'Help', and a language selector set to 'Python'. The main area displays a code cell that has been executed '1 minute ago (2s)'. The code defines a function 'F' that calculates the maximum value of 'quantidade_avaliacoes' and aliases it as 'maximo'. It then displays the results of a query on 'df_distribuicao_volume'. Below the code, there's a performance link and a message 'Checked for improvements'. At the bottom, a table shows the results of the query.

```
F.max("quantidade_avaliacoes")
.alias("maximo")

)

display(df_distribuicao_volume)
```

> [See performance \(1\)](#) ✓ Checked for improvements


> df_distribuicao_volume: pyspark.sql.connect.dataframe.DataFrame = [quantidade_filmes: long, minimo: long ... 5 more fields]

	¹ / ₃ quantidade_filmes	¹ / ₃ minimo	¹ / ₃ percentil_25	¹ / ₃ mediana	¹ / ₃ percentil_75	¹ / ₃ percentil_90	¹ / ₃ maximo
1	17706	1	12	28	75	154	574

Figura 59. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-223650).png | registro em 27/09/2026 às 22:36:50

6. Fato, validação da Ouro e análises de negócio



The screenshot shows a Databricks workspace interface. At the top, there are tabs for different notebooks: 'Home', 'harmonizacao_prata', '08_profiling_qualidade_prata', '09_dimensoes_ouro', '10_fato_avaliacao_ouro', '11_validacao_qualidade_ouro', and '12_analises_negocio'. The '12_analises_negocio' tab is active. Below the tabs, there is a menu bar with 'File', 'Edit', 'View', 'Run', and 'Help'. To the right of the menu bar are buttons for 'Python', 'Full', 'Last edit was 3 minutes ago', 'Run all', 'Serverless', 'Schedule', 'Comments', and 'Share'. The main area displays a Python script snippet:

```
)  
.orderBy("fonte", "sentimento")  
)  
  
display(df_sentimento_fonte)
```

 Below the script, there is a link to 'See performance (1)' and a status 'Checked for improvements'. The execution results are shown as a table with the following data:

	A ^B _C fonte	A ^B _C sentimento	1 ² ₃ quantidade	1.2 percentual
1	IMDb	NEGATIVO	24698	49.81
2	IMDb	POSITIVO	24884	50.19
3	Rotten Tomatoes	NEGATIVO	366614	36.28
4	Rotten Tomatoes	POSITIVO	643932	63.72

Figura 60. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-224239).png | registro em 27/09/2026 às 22:42:39

6. Fato, validação da Ouro e análises de negócio

The screenshot shows a Databricks workspace interface. At the top, there's a search bar and navigation tabs for various notebooks. The active notebook is '12_analises_negocio'. The code in the notebook is a PySpark query that filters for critical reviews and orders them by sentiment. The output is a DataFrame named 'df_rt_criticos'. Below the code, there's a performance check status and a table view of the data.

```
df_rt_criticos.orderBy("categoria_critico", "sentimento")
```

display(df_rt_criticos)


df_rt_criticos: pyspark.sql.connect.dataframe.DataFrame = [categoria_critico: string, sentimento: string ... 2 more fields]

	categoria_critico	sentimento	quantidade	percentual
1	DEMAIS CRÍTICOS	NEGATIVO	260827	34.68
2	DEMAIS CRÍTICOS	POSITIVO	491348	65.32
3	TOP CRITIC	NEGATIVO	105787	40.94
4	TOP CRITIC	POSITIVO	152584	59.06

Figura 61. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-224253).png | registro em 27/09/2026 às 22:42:53

6. Fato, validação da Ouro e análises de negócio



The screenshot displays a Databricks workspace interface. At the top, there's a search bar and navigation tabs for various notebooks. The active notebook is '12_analises_negocio'. Below the notebook title, there's a menu bar with 'File', 'Edit', 'View', 'Run', and 'Help'. The 'Run' tab is selected, showing a code editor with a Python script. The script defines a DataFrame named 'df_evolucao_rt' with columns: 'ano', 'sentimento', 'quantidade', and 'percentual'. The DataFrame contains 15 rows of data, representing sentiment analysis results from 1800 to 1939. The table is displayed in a tabular view, showing the first 15 rows. The columns are: 'ano' (year), 'sentimento' (sentiment), 'quantidade' (quantity), and 'percentual' (percentage). The data shows a mix of positive and negative sentiments over time, with a notable increase in positive sentiment in the early 20th century.

	1.2 ano	1.2 sentimento	1.2 quantidade	1.2 percentual
1	1800	NEGATIVO	28	37.33
2	1800	POSITIVO	47	62.67
3	1923	NEGATIVO	1	100
4	1927	POSITIVO	2	100
5	1928	POSITIVO	1	100
6	1929	NEGATIVO	1	100
7	1931	NEGATIVO	1	100
8	1932	POSITIVO	1	100
9	1933	POSITIVO	1	100
10	1934	POSITIVO	1	100
11	1935	POSITIVO	3	100
12	1936	NEGATIVO	1	100
13	1937	POSITIVO	1	100
14	1938	POSITIVO	1	100
15	1939	NEGATIVO	1	33.33

137 rows | 1.847s runtime | Refreshed 9m ago

Figura 62. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-224313).png | registro em 27/09/2026 às 22:43:13

6. Fato, validação da Ouro e análises de negócio


The screenshot shows the Databricks interface with a notebook titled '12_analises_negocio'. The notebook contains a PySpark query that displays the top 20 movies by quantity of reviews. The results are shown in a table view with columns: id_filme, titulo_filme, and quantidade_avaliacoes.

	^A _C id_filme	^A _C titulo_filme	¹ ₃ quantidade_avaliacoes
1	1614ee301d8fea9d7f45bb8530f2888182498420647ed1705065bf05301af721	Joker	574
2	952ad5e41f46c95f230200b95e26ce0a63a3e7c8d2c8b07f9356ac8e532df12e	Once Upon a Time In Hollywood	554
3	34bc20bb5aa3c6302f9c7494ddc64cc1e196f3607d2865572fc764b8708b6347	Us	535
4	6b07d3a74fb9ed3f93d9dade9cf3c22224aa25f33b932983157e51cd9abb6ad5	Avengers: Endgame	528
5	43af4754116ac09940e0866fdebaa860cb493243e3868f8c0ecbf308947472c0	Captain Marvel	523
6	8e8d0b6f1b367110e4716a21da085722c2ffe37bccfbddc233263e05dc7c64de	A Star Is Born	517
7	22f84f90a0cb5d0c0d7bb6a2091a21d52264020afaa36546ff15f4ad77eb7a81	Black Panther	512
8	8b6206df1d69bc5ab3994f5c33a58f737b9fb8e85de12bace2019f7b3825b388	Star Wars: The Rise of Skywalker	496
9	b6cd77c6eaea3d78ca079d8bd3b9491820605d4a391cd2ebe428afdb873a5779	Solo: A Star Wars Story	474
10	12c6c69eb623a38303272a397add70eaa04d529757343aa6fe12285b7135c17d	Star Wars: The Last Jedi	473
11	4e15055188a33fe3fb3f0f9eb862729f0cad582a01f48e6d7c1bacc65ca0af86	Avengers: Infinity War	472
12	9182d3b2169d6b02752dd28f02e02d2d6d8dd1e0e8f0e4e277247c2ef128e549	Wonder Woman	459

Figura 63. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-224330).png | registro em 27/09/2026 às 22:43:30

6. Fato, validação da Ouro e análises de negócio




The screenshot shows the Databricks interface with a notebook titled '12_analises_negocio'. The notebook contains a Python cell that displays a DataFrame. The output is shown as a table with the following columns: quantidade_filmes, minimo, percentil_25, mediana, percentil_75, percentil_90, and maximo. The first row of data shows values: 17706, 1, 12, 28, 75, 154, and 574.

	1 ^o quantidade_filmes	1 ^o minimo	1 ^o percentil_25	1 ^o mediana	1 ^o percentil_75	1 ^o percentil_90	1 ^o maximo
1	17706	1	12	28	75	154	574

Figura 64. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-224346).png | registro em 27/09/2026 às 22:43:46

6. Fato, validação da Ouro e análises de negócio



The screenshot displays the Databricks interface with a workspace containing several notebooks. The active notebook, '12_analises_negocio', shows a SQL query and its results. The query filters for movies with a minimum rating of 75 and lists the top 15 movies by positive rating proportion. The results table shows columns for movie ID, title, total ratings, and positive ratings.

Limiar mínimo: 75 avaliações
Filmes incluídos na análise: 4,469


FILMES COM MAIOR PROPORÇÃO POSITIVA

	^A _C id_filme	^A _C titulo_filme	¹ ₂ quantidade_avaliacoes	¹ ₂ avaliacoes_positiv
1	b75488331023d25ecb24acc6012277db308db6844c09372d0ff61522408f8ee5	Paddington 2	242	
2	1af1814f0e6043b855db0ee393f839058fc01cbb2e9416849961a9c870aca1f5	Leave No Trace	234	
3	30a768aaaf642638ef13ac8d84988096ebffc1a748ada984fd63f3d4b11bf213	Toy Story 2	169	
4	22f7e5855e3676bc473badf376d4949d3e87696e92666c6e9749ccbe184a7358	Man on Wire	158	
5	be11532e519db494dd8c4f847c06945578990477c93356776a62e4456cb62c49	Taxi to the Dark Side	93	
6	ac529ecbd487f29638bf5845350eadf3c16ae4bf7ce7b16daf2d1bcc3732e220	Citizen Kane	92	
7	0d84260599cd4fac6b2064d4d1223ff2ef5183564881cf9118511c264a796078	Toy Story	90	
8	b2b8b71b19d11427c3e2b067272c4de3d2888733f860f0f4582ca9e53246e498	Crip Camp: A Disability Revolution	84	
9	eaf0954fdf52365e591b4ef77f566ad85c98fe53ad2e3c92530c7ea0ad599f31	GETT: The Trial of Viviane Amsalem	78	
10	8a038440c94a53d0d032ac4aed7cb39c6d06c3edc6f9441ee1a405f8a46ffd4d	A Separation	176	
11	878f164dbade27969b9c6bead00acac4cf32a93e3bf45300ee81f730ec006f2e	Shaun the Sheep Movie	169	
12	bc7f5085d52db5e6bd26258c52c3e3ffaa024475ade6d54756fce06dd1d0fd95	Amazing Grace	157	
13	af325019acad5cc5429c9f74a6f181774b58dd703ec230f9719702b7404de62f	Ash Is Purest White	152	
14	69d8f4302e318af1a27fafbcf61b1d91a1e329a2b059416b869ee0c7e2a35fa2	Things to Come (L'avenir)	143	
15	6c142f89f820dfecad607e5de4ddc61a3c41ad0e49f6c258cabed75d10697e0d	Finding Nemo	266	

Figura 65. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-224404).png | registro em 27/09/2026 às 22:44:04

6. Fato, validação da Ouro e análises de negócio



The screenshot shows the Databricks interface with a notebook titled "12_analises_negocio". The notebook is running a Python script, and the output is displayed in a dark-themed editor. The output includes a summary of business analysis results, formatted with a title "SÍNTESE DAS ANÁLISES DE NEGÓCIO" and several sections: "VOLUMETRIA", "SENTIMENTO GLOBAL", "ANÁLISE POR FILME", and "OBSERVAÇÕES METODOLÓGICAS".

```
print("=" * 68)

> See performance \(6\) ✓ Checked for improvements

=====
SÍNTESE DAS ANÁLISES DE NEGÓCIO
=====

VOLUMETRIA
Avaliações analisadas: 1,060,128
Fontes: 2
Filmes identificados: 17,706
Datas identificadas: 8,015

SENTIMENTO GLOBAL
Positivas: 668,816 (63.09%)
Negativas: 391,312 (36.91%)

ANÁLISE POR FILME
Limiar adotado: 75 avaliações
Filmes acima do limiar: 4,469

OBSERVAÇÕES METODOLÓGICAS
✓ IMDb e Rotten Tomatoes analisados separadamente por fonte
✓ sentimentos harmonizados em POSITIVO e NEGATIVO
```

Figura 66. Evidência da construção/validação da tabela fato e dos resultados utilizados nas análises de negócio.

Arquivo original: image(20260927-224425).png | registro em 27/09/2026 às 22:44:25

7. Organização final do pipeline e catálogo

Evidência da organização dos notebooks e da estrutura efetivamente persistida no Catalog Explorer.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.

7. Organização final do pipeline e catálogo

The screenshot displays the Databricks workspace interface. The left sidebar contains navigation options: Home, Learn, Workspace (selected), Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, Data Engineering, and Runs. The main area shows the 'Workspace' view for the user 'fagundespereira@gmail.com'. It lists various folders and notebooks, including 'Dratts', '.assistant', and a series of notebooks numbered 00 to 12. The notebook '05_rt_filmes_prata.' is highlighted with a star icon.

Name	Type	Owner
Dratts	Folder	fagundespereira...
.assistant	Folder	fagundespereira...
00_Configuracao	Notebook	fagundespereira...
01_ingestao_dados_brutos	Notebook	fagundespereira...
02_camada_bronze	Notebook	fagundespereira...
03_profiling_qualidade_bronze	Notebook	fagundespereira...
04_imdb_prata	Notebook	fagundespereira...
★ 05_rt_filmes_prata.	Notebook	fagundespereira...
06_rt_avaliacoes_prata	Notebook	fagundespereira...
07_integracao_harmonizacao_prata	Notebook	fagundespereira...
08_profiling_qualidade_prata	Notebook	fagundespereira...
09_dimensoes_ouro	Notebook	fagundespereira...
10_fato_avaliacao_ouro	Notebook	fagundespereira...
11_validacao_qualidade_ouro	Notebook	fagundespereira...
12_analises_negocio	Notebook	fagundespereira...

Figura 67. Evidência da organização dos notebooks e da estrutura efetivamente persistida no Catalog Explorer.
Arquivo original: image(20260927-232917).png | registro em 27/09/2026 às 23:29:17

7. Organização final do pipeline e catálogo

The screenshot displays the Databricks Catalog Explorer interface. The left sidebar shows the navigation menu with categories like Home, Learn, Workspace, Recents, Catalog, Jobs & Pipelines, Compute, Discover, Marketplace, SQL, SQL Editor, Queries, Dashboards, Genie Agents, Alerts, Query History, SQL Warehouses, Data Engineering, Runs, Data Ingestion, Visual Data Prep, AI/ML, Playground, Agents, AI Gateway, Experiments, Features, Models, and Serving. The main panel shows the 'Catalog Explorer' view for the path 'mvp3_eng_dados > dados_brutos > volume_dados_brutos'. The 'Overview' tab is selected, showing a description 'Landing Zone dos arquivos originais do MVP-3' and a file list with columns 'Name', 'Size', and 'Last modified'. The file list contains two entries: 'imdb' and 'rotten_tomatoes'. The right sidebar shows 'About this volume' with the owner 'fagundespereira@gmail.com' and a 'Tags' section with an 'Add tags' button.

Figura 68. Evidência da organização dos notebooks e da estrutura efetivamente persistida no Catalog Explorer.

Arquivo original: image(20260927-233135).png | registro em 27/09/2026 às 23:31:35

8. Metadados do catálogo

Evidência da consulta ao `information_schema` para comprovação dos metadados reais das tabelas Bronze, Prata e Ouro.

As páginas seguintes mantêm as capturas originais e identificam cada uma pelo arquivo correspondente. O objetivo é comprovar a execução no Databricks e tornar visível a sequência de decisões, testes e validações.

8. Metadados do catálogo

The screenshot displays the Databricks SQL Editor interface. At the top, there's a search bar and navigation tabs for various workspace elements. The main area shows a SQL query being executed. Below the query, a table of results is displayed, showing metadata for tables in the 'mvp3_eng_dados' catalog, specifically for the 'bronz' schema. The table has columns for table_catalog, table_schema, table_name, column_name, data_type, and comment. The results show five rows of metadata for the 'imdb_avaliacoes' table.

```
1 SELECT
2   table_catalog,
3   table_schema,
4   table_name,
5   column_name,
6   data_type,
7   comment
8 FROM
9   system.information_schema.columns
10 WHERE
11   table_catalog = 'mvp3_eng_dados'
12   AND lower(table_schema) IN ('prata', 'ouro', 'bronz', 'dados_brutos')
```

	table_catalog	table_schema	table_name	column_name	data_type	comment
1	mvp3_eng_dados	bronz	imdb_avaliacoes	review	STRING	null
2	mvp3_eng_dados	bronz	imdb_avaliacoes	sentiment	STRING	null
3	mvp3_eng_dados	bronz	imdb_avaliacoes	_fonte	STRING	null
4	mvp3_eng_dados	bronz	imdb_avaliacoes	_arquivo_origem	STRING	null
5	mvp3_eng_dados	bronz	imdb_avaliacoes	_data_ingestao	TIMESTAMP	null

134 rows | 0.736s runtime | See performance (1) | Checked for improvements | Refreshed Now

Figura 69. Evidência da consulta ao information_schema para comprovação dos metadados reais das tabelas Bronze, Prata e Ouro.

Arquivo original: image(20260927-235701).png | registro em 27/09/2026 às 23:57:01

Síntese das evidências

O conjunto documenta o uso efetivo do Databricks ao longo do MVP: criação e organização da Landing Zone; persistência e inspeção das camadas Bronze, Prata e Ouro; profiling e tratamento de qualidade; integração e harmonização das fontes IMDb e Rotten Tomatoes; construção das dimensões e da tabela fato; validação da granularidade e integridade do modelo; execução das análises de negócio; organização dos notebooks; e consulta aos metadados reais por meio do `information_schema`.

A sequência também evidencia que as transformações não foram tratadas como uma única carga monolítica: foram executadas e verificadas por etapas, com validações intermediárias antes da progressão para a camada seguinte. Essa organização favorece rastreabilidade, reprodutibilidade e compreensão do cuidado adotado na implementação do pipeline.